

Nuestro programa para esta sesión:

Esta segunda clase será dividida en dos partes:

✓ Parte I (20 minutos):

Instalación de Python3 + Anaconda + PyCharm (opcional)

✓ Coffee-break (15 minutos):

Café + galletas + conversación distendida c/r a Python (videos)

✓ Parte 2 (45 minutos):

Revisión de visualización de data usando Matplotlib

Total de la clase: I hora 20 minutos

Autor: Jorge Felipe Monardes Pinto

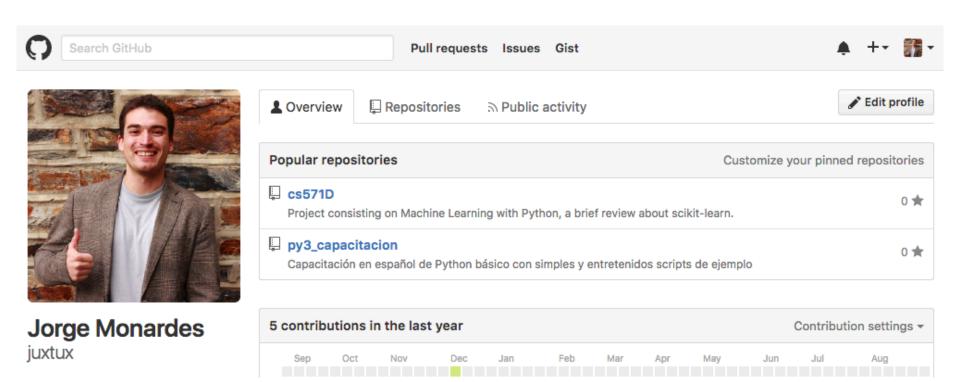




<u>Fuente</u>

Visitar mi repositorio Github : https://github.com/juxtux

Documentación y scripts : https://github.com/juxtux/py3_capacitacion







PARTE I + COFFEE-BREAK







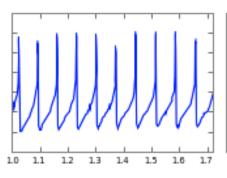
John Hunter (1968-2012)

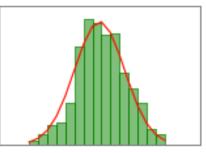


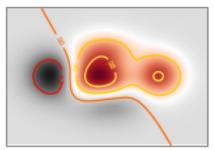
On August 28 2012, John D. Hunter, the creator of matplotlib, died from complications arising from cancer treatment, after a brief but intense battle with this terrible illness. John is survived by his wife Miriam, his three daughters Rahel, Ava and Clara, his sisters Layne and Mary, and his mother Sarah.

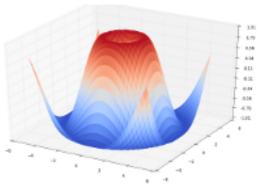
If you have benefited from John's many contributions, please say thanks in the way that would matter most to him. Please consider making a donation to the John Hunter Technology Fellowship.







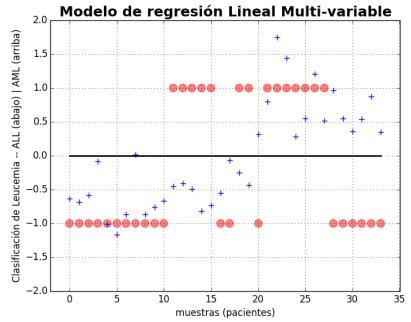








```
__author__ = 'Jorge Monardes'
     import numpy as np
      import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
                                                                Clasificación de Leucemia -- ALL (abajo) | AML (arriba)
      real_y = np.random.uniform(-1, 1, 72)
                                                                   1.5
     axis x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
                                                                   1.0
10
11
                                                                   0.5
12
      plt.plot(axis_x, sep_y, color='black',
13
                linewidth=2)
                                                                   0.0
14
      plt.scatter(axis_x, test_y, color='r',
15
                   alpha=.5, s=100,
                                                                   -0.5
                   label='y-test data real')
17
      plt.scatter(axis_x, real_y,
                   color='b', marker='+', s=60,
19
                                                                  -1.5
20
21
      plt.xlabel('muestras (pacientes)')
                                                                  -2.0
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                  'ALL (abajo) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                 fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
     plt.legend(loc='best')
31
32
33
      plt.show()
```



Se recomienda: http://matplotlib.org/api/ pyplot_summary.html

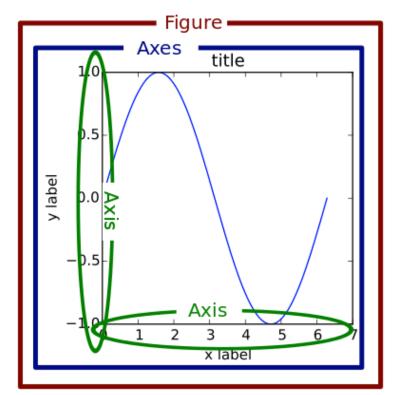


```
everis
an NTT DATA Company
```

```
__author__ = 'Jorge Monardes'
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                 alpha=.5, s=100,
                 label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                 color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
31
     plt.legend(loc='best')
32
33
     plt.show()
```

...is a collection of command style functions that make <u>matplotlib work like MATLAB</u>.

Todo lo que hagan serán métodos sobre plt





Referencia: http://matplotlib.org/users/pyplot_tutorial.html

```
everis
an NTT DATA Company
```

```
__author__ = 'Jorge Monardes'
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                 alpha=.5, s=100,
                 label='v-test data real')
17
     plt.scatter(axis_x, real_y,
                 color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abajo) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
31
     plt.legend(loc='best')
32
33
     plt.show()
```

Simplemente data. Los datos que correspondan al eje x y al eje y, deben estar cuidadosamente seleccionados en forma vectorial, pero no necesariamente en tipo, i.e.,

- o List()
- o Numpy.array()

Ejemplo Numpy en consola

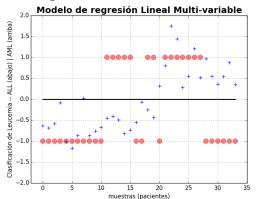


```
everis
an NTT DATA Company
```

```
<u>_author_</u> = 'Jorge Monardes
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                 alpha=.5, s=100,
                  label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                  color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abajo) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
     plt.savefig("myPlot.png")
30
     plt.legend(loc='best')
31
32
     plt.show()
```

plot() se utiliza para líneas y/o curvas continuas

- o plot(x, y): vector con valores de eje-x & vector con valores para el eje-y
- o plot(x, y, color='black'): color de la línea/ curva, también se puede usar c='black'
- o plot(x, y, c='black', linewidth=2): espesor de la línea/curva, se puede usar lw=2, el número utilizado puede ser decimal, e.g., lw=1.3
- o ¿Donde está en el gráfico?



Referencia: http://matplotlib.org/users/pyplot_tutorial.html



```
everis
an NTT DATA Company
```

```
__author__ = 'Jorge Monardes
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
              linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                 alpha=.5, s=100,
16
                 label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                 color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abajo) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
               fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
     plt.savefig("myPlot.png")
30
31
     plt.legend(loc='best')
32
     plt.show()
```

scatter() se utiliza para puntos de dispersión

- o scatter(x, y): vector con valores de eje-x & vector con valores para el eje-y
- o scatter(x, y, color='r'): color de la línea/curva, también se puede usar c='red' o c='r'
- o scatter(x, y, c='r', alpha=.5): grado de transparencia de los puntos de dispersión, el número utilizado debe ser entre 0 (transparente) y | (opaco).
- o scatter(x, y, c='r', alpha=.5, s=100): se refiere al tamaño que tendrán cada uno de los puntos. Utilizar "size" no aplica y debiese dar errores.
- scatter(x, y, c='r', alpha=.5, s=100, label='texto'): corresponde a la etiqueta que utilicemos para esa serie de datos.



```
everis
an NTT DATA Company
```

```
_author__ = 'Jorge Monardes'
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                  alpha=.5, s=100,
                  label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                  color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
31
     plt.legend(loc='best')
32
33
     plt.show()
```

scatter() IDEM

- o scatter(x, y, color='b'): 'b' se refiere a blue, por lo que esta serie será azul.
- o scatter(x, y, color='b', marker='+'): tipo de marcador que queramos utilizar. La variedad estándar disponible abajo (la lista de abajo continua, para más revizar link de referencia.)

| marker | description |
|------------|----------------|
| " " | point |
| 11 11 1 | pixel |
| "o" | circle |
| "V" | triangle_dowr |
| "A" | triangle_up |
| "<" | triangle_left |
| ">" | triangle_right |
| "1" | tri_down |
| "2" | tri_up |
| "3" | tri_left |
| "4" | tri_right |
| "8" | octagon |
| "S" | square |
| "p" | pentagon |
| G★11 | star |
| | |



```
everis
an NTT DATA Company
```

```
__author__ = 'Jorge Monardes'
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                  alpha=.5, s=100,
                  label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                 color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abajo) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable'.
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
     plt.legend(loc='best')
31
32
33
     plt.show()
```

xlabel() & ylabel()

- xlabel('texto...'): simplemente el texto para el eje-x y eje-y, respectivamente.
- xlabel('texto...', fontsize=12, color='b'): es posible realizar más especificaciones de estos métodos, revisar referencias y Googlear!



Referencia: http://matplotlib.org/ api/ pyplot_api.html#matplotlib.pyplo t.xlabel



```
__author__ = 'Jorge Monardes'
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                 alpha=.5, s=100,
                 label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                 color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abajo) | AML (arriba)')
     plt.title('Modelo de regresión Lineal Multi-variable'.
24
25
               fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
     plt.legend(loc='best')
31
32
     plt.show()
```

title(): titulo de la figura.

- o title('texto...'): simplemente el texto para el gráfico.
- o title('texto...', fontsize=18, fontweight='bold'): IDEM a anterior
- fontweight='bold', loc='center'): pruebenlo, con 'center', 'left', y 'right'.

Referencia: http://matplotlib.org/ api/ pyplot_api.html#matplotlib.pyplo t.title

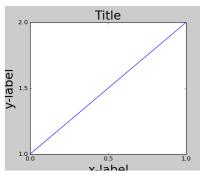


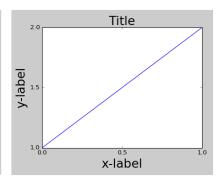


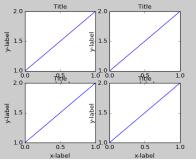
```
__author__ = 'Jorge Monardes'
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
                                                               y-label
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                  alpha=.5, s=100,
                  label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                  color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abajo) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
28
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
31
     plt.legend(loc='best')
32
33
     plt.show()
```

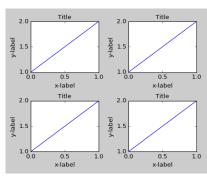
axis(): control de ejes

o axis('tight'):









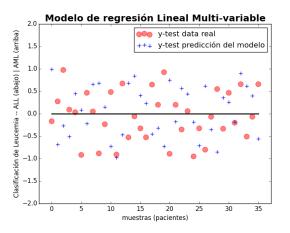


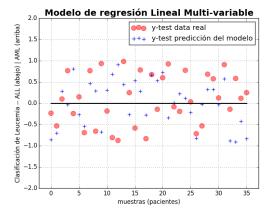


```
_author__ = 'Jorge Monardes'
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real_y = np.random.uniform(-1, 1, 72)
     axis x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                 alpha=.5, s=100,
                 label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                 color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abajo) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
     plt.legend(loc='best')
31
32
     plt.show()
```

grid(): control de grilla

o grid(False) & grid(True):

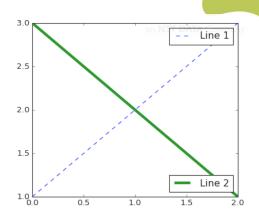




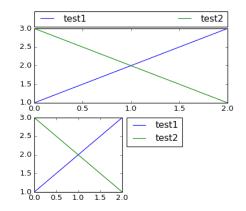


Referencia: http://matplotlib.org/api/axis_api.html

```
_author__ = 'Jorge Monardes
     import numpy as np
     import matplotlib.pyplot as plt
     test_y = np.random.uniform(-1, 1, 72)
     real y = np.random.uniform(-1, 1, 72)
     axis_x = [i for i in range(0,len(test_y))]
     sep_y = [0 for i in range(0,len(test_y))]
10
11
12
     plt.plot(axis_x, sep_y, color='black',
13
               linewidth=2)
14
     plt.scatter(axis_x, test_y, color='r',
15
                 alpha=.5, s=100,
                 label='y-test data real')
17
     plt.scatter(axis_x, real_y,
                 color='b', marker='+', s=60,
19
                  label='y-test predicción del modelo')
20
21
     plt.xlabel('muestras (pacientes)')
22
     plt.ylabel('Clasificación de Leucemia -- '
23
                 'ALL (abaio) | AML (arriba)')
24
     plt.title('Modelo de regresión Lineal Multi-variable',
25
                fontsize=18, fontweight='bold')
27
     plt.axis('tight')
     plt.grid(True)
29
     plt.ylim(-2, 2)
30
     plt.savefig("myPlot.png")
31
     plt.legend(loc='best')
32
     plt.show()
```

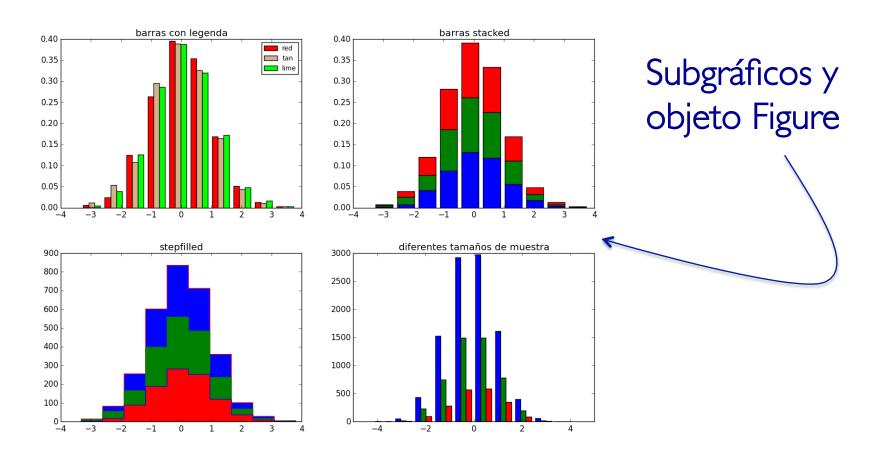


- o ylim(-2, 2): límites del eje-y entre -2 y +2
- o savefig('myPlot.png'): se guarda imagen en formato PNG del gráfico en el directorio de trabajo.
- legend(loc='best'): de establece necesidad de cuadro de legenda con la ''mejor'' localización encontrada.
- o show(): es un must have













```
_author__ = 'Jorge Monardes
      import numpy as np
12
      import matplotlib.pyplot as plt
13
14
      n bins = 10
15
     x = np.random.randn(1000, 3)
16
17
      fig, axes = plt.subplots(nrows=2, ncols=2)
18
     ax0, ax1, ax2, ax3 = axes.flat
19
20
21
22
      colors = ['red', 'tan', 'lime']
     ax0.hist(x, n_bins, normed=1, histtype='bar',
               color=colors, label=colors)
23
24
25
26
27
28
29
30
31
32
      ax0.legend(prop={'size': 10})
     ax0.set_title('barras con legenda')
     ax1.hist(x, n_bins, normed=1, histtype='bar',
               stacked=True)
     ax1.set title('barras stacked')
      ax2.hist(x, n_bins, histtype='step',
               stacked=True, fill=True)
     ax2.set_title('stepfilled')
33
34
     # Make a multiple-histogram of
35
      # data-sets with different length.
     x_multi = [np.random.randn(n) for n in [10000, 5000, 2000]]
37
     ax3.hist(x_multi, n_bins, histtype='bar')
38
     ax3.set_title('diferentes tamaños de muestra')
39
40
      plt.tight_layout()
      plt.show()
```

Librerías de siempre

- o Queremos diez quantiles (percentiles)
 - o Data random con distribución normal estandarizada N(0,1). Queremos 3,000 puntos divididos en tres grupos (matriz de mil filas y tres columnas.)

subplots(nrows=r, ncols=c): estrega una lista con el objeto figure y una lista de los objetos subgraphs que se generan mediante el número de filas "r" y el número de columnas "c".

En este elemplo plt.subplots(nrow=2, ncols=2):





```
_author__ = 'Jorge Monardes
                                                                                                                an NTT DATA Company
                                                                            fig = plt.figure()
                                                                                                       subplot1() , subplot2()
                                                                                          axes =
11
12
13
14
15
16
      import numpy as np
                                                                                                       subplot3() , subplot4()
      import matplotlib.pyplot as plt
      n_bins = 10
     x = np.random.randn(1000, 3)
17
     fig, axes = plt.subplots(nrows=2, ncols=2)
                                                                                   subplot I () , subplot2(), subplot3(), subplot4()
18
      ax0, ax1, ax2, ax3 = axes.flat
19
20
      colors = ['red', 'tan', 'lime']
21
22
      ax0.hist(x, n_bins, normed=1, histtype='bar',
                                                                       ax0 = subplot I()
               color=colors, label=colors)
23
24
25
26
27
28
29
30
31
32
      ax0.legend(prop={'size': 10})
      ax0.set_title('barras con legenda')
                                                                       axI = subplot2()
      ax1.hist(x, n_bins, normed=1, histtype='bar',
                                                                       ax2 = subplot3()
               stacked=True)
     ax1.set title('barras stacked')
                                                                       ax3 = subplot4()
      ax2.hist(x, n_bins, histtype='step',
               stacked=True, fill=True)
     ax2.set_title('stepfilled')
33
34
     # Make a multiple-histogram of
35
      # data-sets with different length.
36
      x_multi = [np.random.randn(n) for n in [10000, 5000, 2000]]
37
      ax3.hist(x_multi, n_bins, histtype='bar')
38
      ax3.set_title('diferentes tamaños de muestra')
39
40
      plt.tight_layout()
      plt.show()
```





```
<u>author</u> = 'Jorge Monardes
11
12
13
14
15
16
      import numpy as np
      import matplotlib.pyplot as plt
      n bins = 10
      x = np.random.randn(1000, 3)
17
      fig, axes = plt.subplots(nrows=2, ncols=2)
18
      ax0, ax1, ax2, ax3 = axes.flat
19
20
21
22
      colors = ['red', 'tan', 'lime']
      ax0.hist(x, n_bins, normed=1, histtype='bar',
                color=colors, label=colors)
23
24
25
26
27
28
29
30
31
32
33
      ax0.legend(prop={'size': 10})
      ax0.set_title('barras con legenda')
      ax1.hist(x, n_bins, normed=1, histtype='bar',
                stacked=True)
      ax1.set title('barras stacked')
      ax2.hist(x, n_bins, histtype='step',
                stacked=True, fill=True)
      ax2.set title('stepfilled')
      # Make a multiple-histogram of
      # data-sets with different length.
      x_multi = [np.random.randn(n) for n in [10000, 5000, 2000]]
37
      ax3.hist(x_multi, n_bins, histtype='bar')
38
      ax3.set_title('diferentes tamaños de muestra')
39
40
      plt.tight_layout()
      plt.show()
```

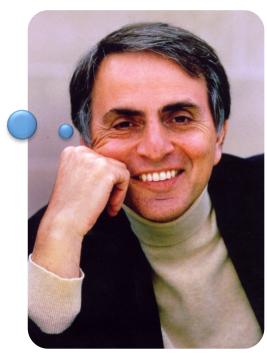
Same old story...



Últimas palabras...



"If you want to make an apple pie from scratch, you must first, invent the universe."



Prof. Carl Sagan 1934 - 1996

